# VLA Quantization Paper – (SQAP-VLA / QVLA / HBVLA / QuantVLA / DyQ-VLA / DA-PTQ)

26/04/17

## 1) SQAP-VLA

**[해결 문제]**

**VLA 모델을 압축하기 위해 토큰 푸루닝(Token pruning)과 양자화(Quantization)를 단순 결합할 경우, 양자화 노이즈가 어텐션 맵(Attention map)을 심각하게 왜곡시켜 푸루닝 성능이 치명적으로 저하되는 근본적인 충돌(Incompatibility) 문제를 해결하고자 한다.**

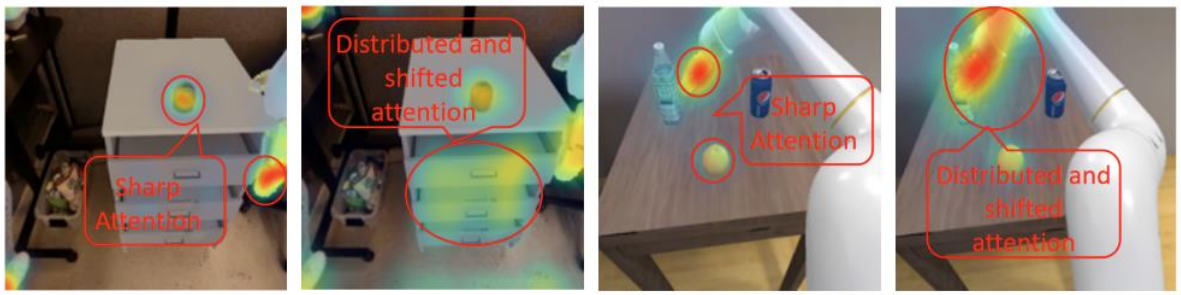


(a) Full-precision model. (b) Quantized model. (c) Full-precision model. (d) Quantized model.

Figure 2: The attention heatmap before and after quantization. (a) and (c) Before quantization, attention is sharply focused. (b) and (d) After quantization, the attention becomes scattered and shifted.

**[Contribution]**

- **양자화와 토큰 푸루닝의 근본적인 충돌 문제를 식별하고 이를 해결하는 양자화 인지 푸루닝(Quantization-aware pruning) 공동 설계 프레임워크 제안**
- **양자화 노이즈에 강건한 상위 어텐션 토큰 보존, 로봇 팔의 3D 물리적 좌표 투영을 통한 보호, 공간 샘플링(FPS) 기법 도입**
- **아다마르 변환(Hadamard transform)을 적용해 활성화 값의 이상치(Outlier)를 억제하여 어텐션 분포를 매끄럽게 만들고 양자화 효율 극대화**

**[핵심 한 문장]**

**양자화로 인한 어텐션 맵 왜곡 문제를 아다마르 변환과 로봇 공간 좌표 투영법으로 해결하여, 토큰 푸루닝과 양자화의 시너지를 극대화한 프레임워크입니다.**

**[Quantization 설정]**

- **Static/Dynamic: Static PTQ**
- **Weight-only / Weight-Activation: Weight-Activation (W4A4)**
- **Granularity: Per-tensor**
- **Quantized Modules: 모델 전체 (특히 시각-언어 인터페이스의 Query/Key 활성화 값 및 가중치 집중 적용)**

**[Method]**

**Query/Key 레이어에 아다마르 회전(Hadamard rotation)을 적용해 활성화 이상치를 억제한 뒤 W4A4 텐서 단위 양자화를 수행합니다. 동시에 양자화에도 변하지 않는 상위 어텐션 토큰, 로봇 팔 좌표에 해당하는 보호 토큰, 공간 샘플링 토큰만을 남기는 푸루닝을 결합합니다.**

**[Baseline]**

**CogACT (FP16), FastV, VLA-Cache, EfficientVLA 등**

**[Benchmark]**

- **환경: SimplerEnv (Visual Matching, Variant Aggregation)**
- **평가 Metric: Success rate, Speed-up, Peak GPU memory**

**[Result]**

**기준 모델 대비 메모리 사용량을 14.3GB에서 7.6GB로 절반 가까이 줄였으며, 1.93배의 추론 속도 향상과 함께 Visual Matching 환경에서 평균 성공률을 4.5% 향상**

**[Insight]**

**로봇 AI 모델에서 압축 기법(푸루닝과 양자화)을 단순히 이어 붙이는 것은 내부 데이터 분포 왜곡으로 인해 실패를 초래하므로, 상호 영향을 고려한 공동 최적화(Co-design)가 필수적임을 시사합니다.**

## 2) QVLA

**[해결 문제]**

**기존 LLM 방식의 일괄적인 양자화(Uniform-bit) 기법은 VLA 모델에서 발생하는 단일 스텝의 미세한 오차가 폐루프(Closed-loop) 환경을 거치며 치명적인 장기 궤적 이탈(Catastrophic failure)로 누적되는 물리적 나비효과를 무시하는 문제를 해결하고자 한다.**

**[Contribution]**

- **VLA 모델에서 최초로 최종 행동 공간(Action space)에 미치는 민감도를 테일러 전개(Taylor-series approximation)로 측정하는 방법론 도입**
- **측정된 민감도를 바탕으로 가장 덜 중요한 채널부터 비트를 깎아내는 전역 탐욕 강등(Global greedy demotion) 알고리즘 제안**
- **채널별 혼합 정밀도 양자화와 0비트 푸루닝을 하나의 프레임워크로 통합**

**[핵심 한 문장]**

**내부 수치 복원이 아닌 최종 행동(Action) 공간에 미치는 영향을 야코비안으로 계산하여, 채널 단위로 최적의 비트(0~16)를 할당하는 행동 중심 양자화**

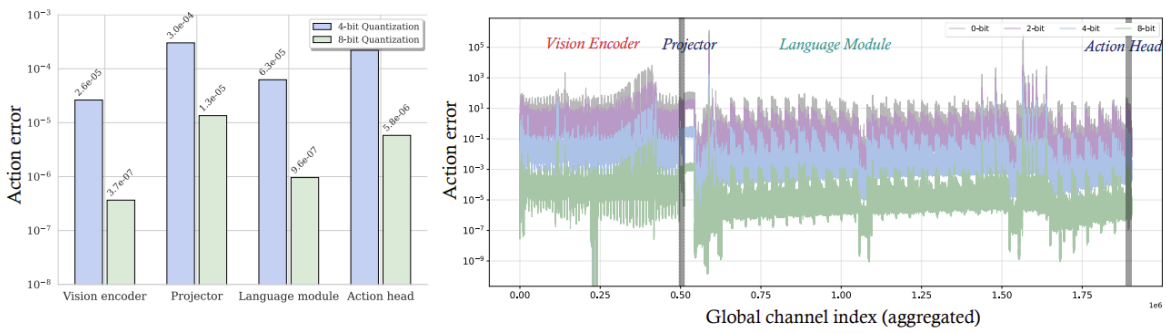


(a) Quantization Results Across Modules (b) Quantization Results Across Channels

Figure 1: Quantitative analysis of quantization sensitivity in VLA models. **(a)** Per-module analysis shows that the projector and action head are significantly more sensitive to quantization. **(b)** Per-channel analysis demonstrates highly heterogeneous sensitivity within modules. These findings collectively motivate our adaptive precision, channel-level quantization approach.

**Module 별, 그리고 Channel-wise로 민감도를 측정해야한다.**

**[Quantization 설정]**

- **Static/Dynamic: Static PTQ**
- **Weight-only / Weight-Activation: Weight-Activation (W8A8, W4A4 등) 및 Weight-only (W8A16, W4A16)**
- **Granularity: Per-channel**
- **Quantized Modules: Vision encoder, Language module (안정성을 위해 Projector와 Action head는 BF16으로 유지)**

**[Method] 각 채널이 행동 출력에 미치는 영향을 야코비안 행렬 기반의 테일러 1차 근사로 측정하여 전역 채널 순위를 매깁니다. 이후 목표 비트 예산에 맞춰 덜 민감한 채널부터 16->8->4->2->0 비트 순으로 정밀도를 낮추거나 푸루닝(0비트)합니다.**

**[Baseline] OpenVLA, OpenVLA-OFT (비교 방법론: SmoothQuant, OmniQuant, AWQ)**

**[Benchmark]**

- **환경: LIBERO (Spatial, Object, Goal, Long), CALVIN, Real robot (IMETA-Y1)**
- **평가 Metric: Success rate, Memory (GB), Speedup, Cumulative Action Error**

**[Result] LIBERO 환경에서 OpenVLA-OFT에 W4A4 적용 시 기존 메모리의 29.2%만 사용하면서도 원본 성능의 98.9%를 유지하고 1.49배 속도 향상을 기록했습니다. LLM용 SmoothQuant 대비 평균 22.6% 성능 우위를 달성했습니다.**

**[Insight] 로봇 AI 양자화는 일반 AI처럼 '수학적 내부 데이터 복원'에 집중할 것이 아니라, 오차가 물리적 세계로 출력되는 '행동(Action) 공간 중심'으로 평가 기준을 완전히 전환해야 함을 증명합니다.**

## 3) QuantVLA

**[기존 문제]**

**해결 문제: 상위 언어 모델의 양자화 오차가 확산 트랜스포머(DiT) 기반의 액션 헤드로 전파될 때, 로짓(Logits)의 온도와 잔차 스트림(Residual stream) 에너지가 뒤틀리는 Scale drift 현상이 발생하여 로봇 제어 정책이 붕괴되는 문제를 해결하고자 한다.**

- ⇨ **즉, DiT action head VLA에 대한 PTQ 논문**

**[Contribution]**

- **VLA 시스템 내 DiT 액션 헤드에 성공적으로 적용된 최초의 PTQ 프레임워크**
- **LLM module은 attention projection(Wq, Wk, Wv, Wo) 및 MLP layer 모두 양자화하는 반면, DiT 액션 헤드는 MLP만 양자화하여 attention projection은 부동소수점으로 남기는 선택적 양자화 레이아웃 제안**
- **런타임 오버헤드 없이 역양자화의 스케일을 보정하기 위한 가벼운 어텐션 로짓 보정(ATM) 및 출력 헤드 보정(OHB) 도입**

**[Summary]**

**DiT 기반 액션 헤드에서 발생하는 attention logit 및 출력 drift 문제를 수학적 스케일 보정(ATM, OHB)을 통해 런타임 비용 없이 해결한 VLA 전용 양자화 프레임워크**

**[Quantization Config]**

- **Static/Dynamic: Static PTQ**
- **Weight-only / Weight-Activation: Weight-Activation (W4A8, W4A4)**
- **Granularity: Per-channel (Weights), Per-token (Activations) / Per-head (ATM), Per-layer (OHB)**
- **Quantized Modules: LLM의 모든 Linear layer 및 DiT의 MLP block (단, DiT의 Q, K, V, O Attention projection은 부동소수점 유지)**

[Method]

DuQuant 기반의 블록 직교 회전 및 스무딩을 적용합니다. 캘리브레이션 단계에서 교사 모델과 학생 모델 간의 로짓 표준편차를 맞추는 ATM 스칼라(Head 단위)와 잔차 스트림 에너지를 맞추는 OHB 스칼라(Layer 단위)를 계산한 뒤, 이 스칼라 값들을 추론 시 기존 디양자화(Dequantization) 스케일 값에 곱하여 병합(Fold)합니다.

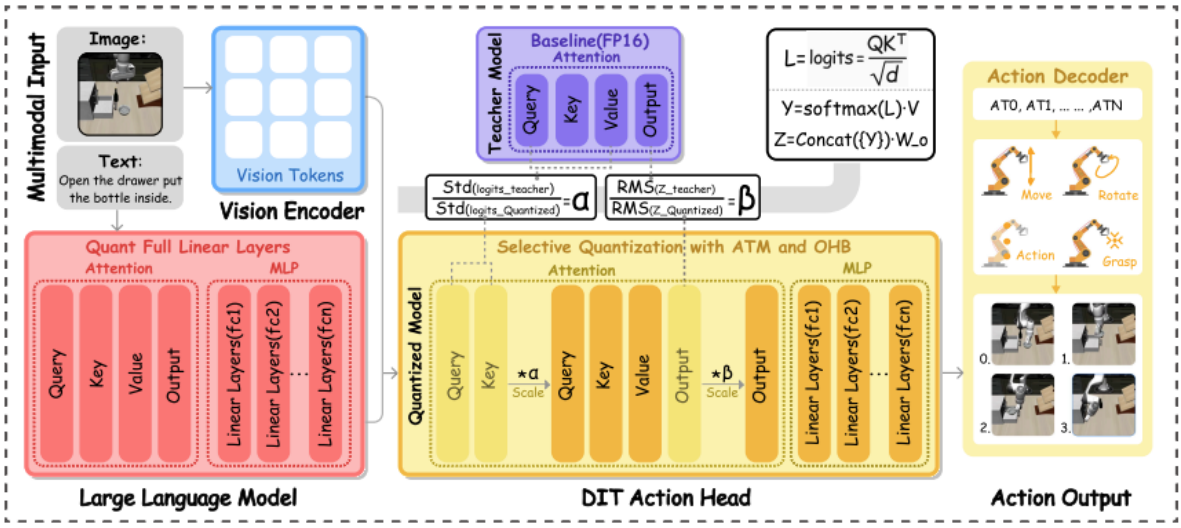


Figure 2. Overview of **QuantVLA** for VLAs with a DiT-based action head. The framework is training-free and preserves the original architecture and operator schedule. It combines: (1) a selective quantization layout that integerizes all linear layers in the LLM and all MLP layers in the DiT while keeping the attention projections $Q, K, V, O$ in floating point; (2) *Attention Temperature Matching* (ATM), a per-head scalar $\alpha$ that aligns teacher–student logits and is folded into dequantization scales; and (3) *Output Head Balancing* (OHB), a per-layer scalar $\beta$ that matches post-projection energy at the residual interface.

[Baseline]

pi0.5, GR00T N1.5, OpenVLA (비교 방법론: SmoothQuant, DuQuant)

[Benchmark]

- 환경: LIBERO, Pick-and-Can
- 평가 Metric: Success rate, Memory savings (GB)

[Result]

pi0.5 모델에서 기준(97.1%)을 초과하는 평균 성공률 97.6%를 달성하면서도 양자화 모듈의 메모리 사용량을 4.27GB에서 1.28GB로 약 70% 감소

[Insight] Vision encoder와 LLM은 Action Head보다 quantization에 robust하다. 시각-언어 추론부와 DiT 제어부 사이의 인터페이스는 스케일 불일치에 극도로 취약하지만, 매우 가벼운 통계적 스칼라 보정만으로도 전체 연산 구조 변경 없이 안정적인 초저비트 제어가 가능함을 입증.

## 4) HBVLA

[해결 문제]

VLA 모델을 1-bit 수준으로 극단적으로 이진화(Binarization)할 때, 방대한 배경 이미지(Outlier)와 시각 토큰의 불균형이 헤시안(Hessian) 행렬을 무너뜨려 실제 로봇 제어에 중요한 가중치를 제대로 찾아내지 못해 정책(Policy)이 붕괴되는 문제를 해결하고자 한다.

[Contribution]

- 시각 이상치에 압도되지 않도록, 행동 생성에 미치는 토큰 중요도로 가중치를 재조정한 정책 인지(Policy-aware) 헤시안 제안
- 비중요(Non-salient) 가중치의 이질적인 크기 도약을 억제하기 위해, 희소 직교 변환(Sparse orthogonal transform)을 결합한 Haar 도메인 이진화 도입
- VLA 모델에 맞춘 1-bit 초저정밀도 이진화 달성 및 실제 로봇 환경에서의 강건성 검증

[핵심 한 문장]

VLA의 특성을 반영한 정책 인지 헤시안으로 핵심 가중치를 보호하고, 희소 직교 변환 및 Haar 웨이블릿 변환을 결합해 노이즈를 억제한 1-bit 이진화 프레임워크

[Quantization 설정]

- Static/Dynamic: Static PTQ
- Weight-only / Weight-Activation: Weight-only (1-bit / 평균 1.08 bit)
- Granularity: Group-wise / Row-wise (Haar 도메인 내)
- Quantized Modules: Vision backbone, Language backbone (Projector와 Action head는 Full precision 유지)

**[Method]**

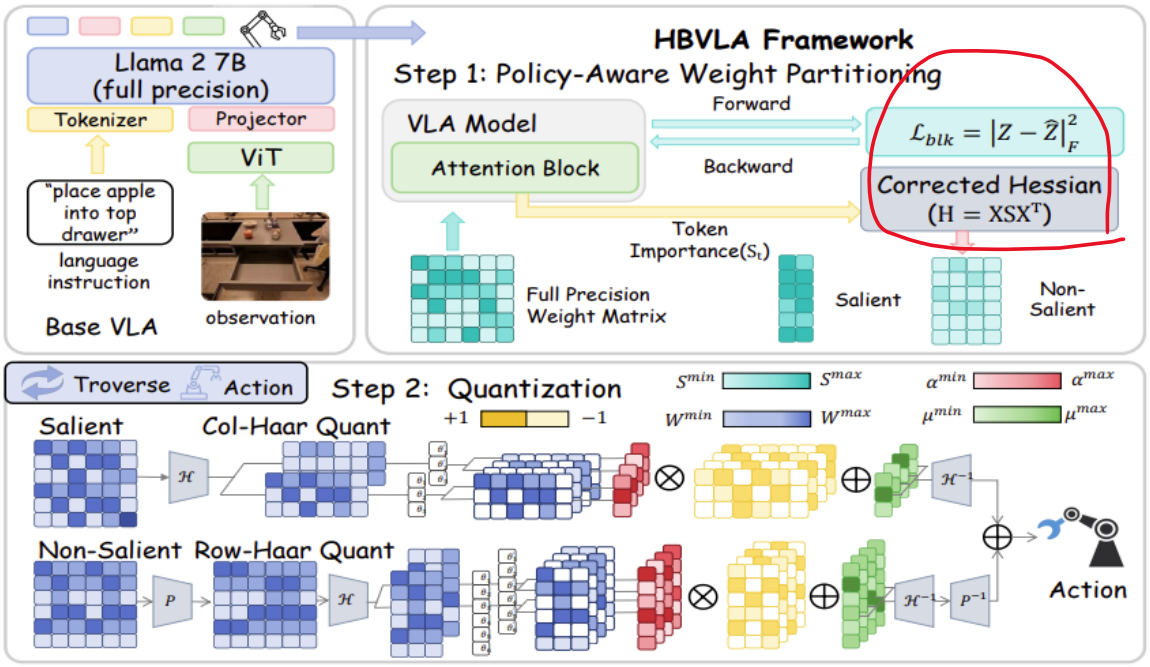


Figure 2: The pipeline of our **HBVLA** framework consists of two steps: (i) In Step 1, we establish a block-wise gradient probe to derive token importance scores ($S_t$) and construct a **Corrected Hessian** proxy to identify *functionally salient* weights grounded in the policy. (ii) In Step 2, we apply a hybrid quantization strategy: salient weights undergo high-fidelity residual quantization, while non-salient weights are processed via sparse orthogonal transform ($P$) and Haar wavelet transform ($\mathcal{H}$) prior to group-wise 1-bit quantization.

**모든 token이 중요하지 않다.**

**Vision token이 Language token 보다 압도적으로 많아 instruction이 희석된다.**

**Action 생성에 중요한 token을 기준으로 hessian을 구성해야한다.**

**블록 단위 gradient를 통해 정책 인지 헤시안을 구성하여 중요(Salient) 가중치와 비중요 가중치를 나눕니다. 비중요 가중치는 희소 직교 변환으로 컬럼을 정렬한 뒤 Haar 웨이블릿 변환 후 그룹 단위 공유 평균(Shared-mean) 이진화를 적용하고, 중요 가중치는 잔차(Residual) 이진화를 통해 보완합니다.**

together with its quantized counterpart $\hat{\Phi}(\cdot)$ under the current binary weights. Given the same input $\mathbf{X} \in \mathbb{R}^{d\times N}$, the corresponding outputs are

$$\mathbf{Z} = \Phi(\mathbf{X}), \qquad \hat{\mathbf{Z}} = \hat{\Phi}(\mathbf{X}), \tag{4}$$

and the binarization-induced deviation of this block is measured by

$$\mathcal{L}_{\text{blk}} = \|\mathbf{Z} - \hat{\mathbf{Z}}\|_F^2. \tag{5}$$

This block alignment loss provides a lightweight calibration objective that isolates the local distortion introduced by binarization, avoiding confounding factors from end-to-end policy optimization.

**Backward.** A single, locally isolated backpropagation on $\mathcal{L}_{\text{blk}}$ captures gradients at the attention projections $(Q, K, V, O)$, identifying the primary pathways where binarization noise distorts the attention mechanism. Let $\mathcal{P} = \{Q, K, V, O\}$ index the projection outputs $\mathbf{Y}^{(p)} \in \mathbb{R}^{d_p\times N}$. The cached gradients are

$$\mathbf{G}^{(p)} \triangleq \frac{\partial \mathcal{L}_{\text{blk}}}{\partial \mathbf{Y}^{(p)}} \in \mathbb{R}^{d_p\times N}, \qquad p \in \mathcal{P}. \tag{6}$$

A larger $\|\mathbf{G}^{(p)}_{:,t}\|$ indicates that perturbing token $t$ at projection $p$ would incur a larger deviation at the block output, hence stronger sensitivity to binarization along the action computation route.

**Process Grad.** Token-wise importance is computed *per projection* by column-wise $\ell_2$ aggregation of the cached gradients, capturing how strongly each token affects the attention computation along a specific linear pathway:

$$a_t^{(p)} \triangleq \frac{1}{d_p}\left\|\mathbf{G}^{(p)}_{:,t}\right\|_2, \qquad p \in \mathcal{P}. \tag{7}$$

Subsequently, we encapsulate these scores into a diagonal importance matrix for each projection:

$$\mathbf{S}^{(p)}_{\text{attn}} \triangleq \operatorname{Diag}\left(a_1^{(p)}, \ldots, a_N^{(p)}\right), \qquad p \in \mathcal{P}. \tag{8}$$

Leveraging this weighting term, we derive the corresponding rectified Hessian proxy:

$$\tilde{\mathbf{H}}^{(p)}_{\text{attn}} \triangleq \mathbf{X}\mathbf{S}^{(p)}_{\text{attn}}\mathbf{X}^\top, \qquad p \in \mathcal{P}, \tag{9}$$

**[Baseline] OpenVLA, OpenVLA-OFT, CogACT (비교 방법론: BiLLM, BiVLM, HBLLM)**

**[Benchmark]**

- **환경: LIBERO, SIMPLER, Real robot (Mobile ALOHA)**
- **평가 Metric: Success rate**

**[Result]**

**LIBERO 환경에서 OpenVLA-OFT 1-bit 양자화 적용 시 기존 성능의 92.2%를 유지했으며, SIMPLER 환경의 CogACT 모델에서는 기존 성능의 93.6%를 유지하여 기존 이진화 기법(BiLLM 등)을 압도했습니다.**

**[Insight]**

**Text, Vision token들간 action sensitivity가 다르다.**

**극단적인 1-bit 압축 환경에서는 모델 내 다양한 모달리티(시각, 언어)의 이질적인 분포가 치명적 노이즈로 작용하므로, 이를 평탄화하기 위한 주파수 도메인 변환(Haar)과 정책 기반 중요도 재조정이 필수적이다.**

## 5) DyQ-VLA

[해결 문제]

로봇의 임무 단계(예: 거친 이동 vs 정밀 조작)에 따라 요구되는 양자화 오차 허용치가 크게 변동(Temporal-dynamic)함에도 불구하고, 기존의 정적(Static) 양자화는 가장 민감한 찰나의 순간에 맞춰 전체 모델을 높은 정밀도로 고정하여 막대한 연산 자원을 낭비하는 문제를 해결하고자 합니다.

[Contribution]

- VLA 모델의 양자화 민감도가 시간에 따라 변동한다는 특성을 규명하고, 이를 로봇의 실시간 물리적 움직임(Kinematic metrics)과 상관관계로 연결
    - 시간에 따르기 보다는, 현재 수행하는 action의 정밀의 필요성
- 모션 정밀도(Motion Fineness)와 각도 저크(Angular Jerk)를 실시간 프록시로 활용하여 비트 전환 시점을 결정하는 민감도 인지 스위칭 전략 도입
    - 로봇의 관절을 고려한 Proxy 민감도 측정
- 민감도에 따라 최적의 활성화 비트(2, 4, 8, 16)를 실시간 할당하는 기구학 기반 비트 할당 모듈 설계 (CPU-GPU 비동기 파이프라인 활용)

[핵심 한 문장]

로봇 팔의 실시간 물리적 움직임을 지표로 삼아, 정밀 조작 시에는 높은 비트를, 단순 이동 시에는 낮은 비트를 동적으로 스위칭하여 연산 효율을 극대화한 프레임워크입니다.

[Quantization 설정]

- Static/Dynamic: Dynamic (Weight는 Static 유지, Activation만 Dynamic 변환)
- Weight-only / Weight-Activation: Weight-Activation (Weight: INT4 고정, Activation: Step/Chunk에 따라 BF16 / INT8 / INT4 / INT2 동적 스위칭)
- Granularity: Not specified for spatial (Temporally varying per-step/chunk)
- Quantized Modules: LLM Backbone

**[Method]**

**가중치는 INT4로 고정하여 메모리 대역폭을 확보합니다. CPU에서 비동기적으로 로봇의 Motion Fineness와 Angular Jerk를 계산해 현재의 민감도를 평가하고, 설정된 임계값에 따라 가장 낮은 오차를 보장하는 최적의 활성화 비트 폭(BF16 또는 INT8/4/2)을 선택하여 GPU의 커널을 런타임에 동적으로 전환합니다.**

**[Baseline]**

**OpenVLA (비교 방법론: SmoothQuant, QVLA)**

**[Benchmark]**

- **환경: LIBERO, Real-world robot**
- **평가 Metric: Success rate, Peak Memory (GB), End-to-End Latency (Speedup)**

**[Result]**

**전체 메모리 풋프린트의 30.9%만 사용하면서도 원본 성능의 99.5%를 유지했으며, 시뮬레이션에서 1.49배, 실제 로봇 환경에서 최대 1.43배의 추론 속도 (Latency) 향상을 달성했습니다.**

**[Insight]**

**물리적 환경에서 움직이는 AI 에이전트는 항상 최고의 연산력을 필요로 하지 않으며, 로봇의 물리적 상태(Kinematics) 자체를 실시간 AI 연산 최적화의 제어 신호로 역이용할 수 있는 새로운 동적 할당 패러다임을 제시합니다.**

## 6) DA-PTQ

[해결 문제]

기존 PTQ 방식은 시각-언어-행동 인터페이스에서 발생하는 미세한 양자화 오차가 순차 제어(Sequential control) 과정과 로봇 관절 구조를 타고 기하급수적으로 증폭되어 심각한 '기구학적 궤적 이탈(Kinematic drift)'을 일으키는 문제를 모델링하지 못하는 한계를 해결하고자 합니다.

기존은 시간에 따른 누적 고려 X

DA-PTQ는 시간을 고려하기 위해 Proxy 가상 야코비안 도입

[Contribution]

- VLA 양자화를 단순한 수치 복원이 아닌, 에러 누적과 궤적 이탈을 억제하는 드리프트 인지(Drift-aware) 최적화 문제로 재정의
- 가상의 구조적 야코비안(Structural Jacobian)을 도입하여 물리적 나비효과를 예측해 레이어별 비트를 할당하는 DA-MPA 도입
- 양자화 전후의 채널 간 입체적 분포 왜곡을 어파인(Affine) 변환으로 일치시킨 뒤 가중치에 병합(Folding)하여 런타임 오버헤드를 없앤 CSRC 도입

[핵심 한 문장]

인공지능 내부의 양자화 오차가 시간에 따라 로봇의 물리적 궤적 이탈(Drift)로 어떻게 증폭될지를 야코비안 수학으로 예측해 비트를 할당하고 데이터 왜곡을 사전 보정하는 로봇 공학 결합형 양자화 기법입니다.

[Quantization 설정]

- Static/Dynamic: Static PTQ
- Weight-only / Weight-Activation: Weight-Activation (W4A8 및 BF16 혼합)
- Granularity: Layer-wise (MPA), Channel-wise 및 Cross-channel (CSRC)
- Quantized Modules: Diffusion Action Head(DiT)의 MLP layers, Vision-Language-to-Action interface

[Method]

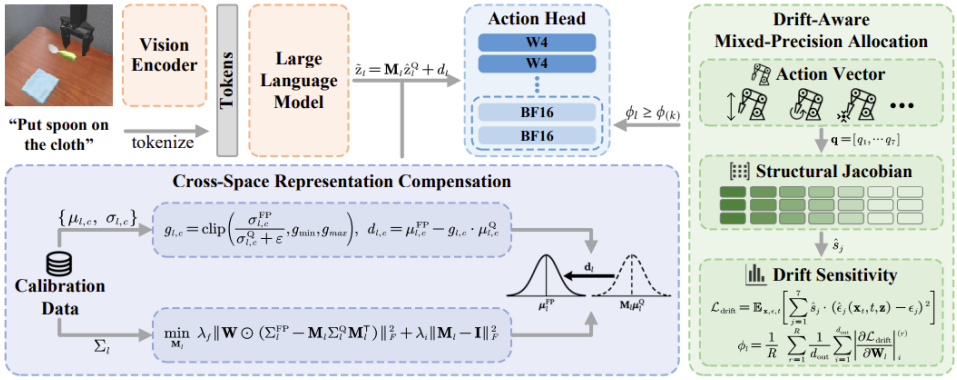


Figure 2: Overview of our proposed DA-PTQ framework. DA-PTQ enables efficient and robust diffusion-based VLA models through two key components: (1) Cross-Space Representation Compensation, which aligns distorted conditioning representations with their full-precision counterparts; and (2) Drift-Aware Mixed-Precision Allocation, which leverages structural Jacobian-based sensitivity to mitigate compounding trajectory drift.

캘리브레이션 단계에서 가상 2D 다관절 로봇의 구조적 야코비안 행렬을 이용해 특정 레이어 오차가 궤적 이탈에 미치는 민감도를 계산, 상위 $k%$ 레이어는 BF16으로 보호하고 나머지는 W4로 압축(DA-MPA)합니다. 동시에 인터페이스에서 발생한 양자화 전후의 경험적 공분산 행렬 왜곡을 SVD 어파인 변환으로 맞춰준 뒤 이를 양자화된 가중치에 해석적으로 흡수(CSRC)시킵니다.

[Baseline] CogACT (비교 방법론: VLA-Cache, QuantVLA)

[Benchmark]

- 환경: SimplerEnv (WidowX In-domain, Google Robot Zero-shot Cross-domain)
- 평가 Metric: Success rate, Memory reduction (%), Speedup

[Result]

WidowX 환경에서 메모리 42.5% 감소 및 추론 속도 54.8% 향상을 달성하면서도 평균 성공률 48.9%를 기록하여 기존 QuantVLA(43.5%)를 누르고 원본 FP 모델(51.3%)과의 격차를 크게 좁혔습니다.

[Insight]

소프트웨어(AI)의 에러를 압축하고 평가할 때, 데이터 라벨이나 손실 함수가 아닌 로봇의 순수 물리 역학 공식(Jacobian) 자체를 미분 가능한 채점 기준으로 주입하는 융합(Integration)이 Physical AI 효율화의 핵심임을 시사합니다.